



- Une définition
- MapReduce
- 3 Hadoop
- Bases NoSQL

- Travaux dirigés
- **1** Travaux pratiques







MapReduce

Hadoop

Bases NoSQL

Travaux dirigés

- ⊳ Web
- ▷ Réseaux sociaux
- Logs
- Données de ventes





MapReduce Hadoop

Bases NoSQL

Travaux dirigés

Travaux uirig

- ⊳ Web
 - Recherche de contenus
- ▶ Réseaux sociaux
 - Analyse de relations
- - Détection de pannes
- - Amélioration des algorithmes
- Données de ventes
 - Optimisation marketing



Déroulement d'un projet BigData

▶ Une définition

MapReduce Hadoop

Bases NoSQL

Busco Hood

Travaux dirigés

- - Est-un problème BigData ?
- ⊳ Nettoyage de la donnée
- ▷ Analyse



Quelques points importants

▶ Une définition

MapReduce

нацоор

Bases NoSQL

Travaux dirigés

- - Images, Musiques, Textes
- Données semi-structurées
 - Logs, JSON, XML
- ⊳ flux continus
- ▷ Les géants du Web sont les pionniers du BigData
 - Google
 - Facebook
 - Yahoo!
 - LinkedIN





MapReduce Hadoop

Bases NoSQL

Duscs Hood

Travaux dirigés

- \triangleright octet = 8 bits
 - 256 valeurs distinctes
 - un caractère non exotique
- ▷ Kilooctet = 1000 octets, Kibioctet = 1024 octets
 - Un poème
- ▷ Mégaoctet = 1000 Kilooctets
 - Une photographie de qualité moyenne
 - Une nouvelle
 - Capacité de stockage d'une disquette





MapReduce

Bases NoSQL

....

Travaux dirigés

- ▷ Gigaoctet
 - Un film compressé
 - Une remorque de livres
 - Capacité de stockage d'un CD/DVD
- - Une bibliothèque universitaire
 - 50000 arbres transformés en journaux
 - Capacité de stockage d'un disque dur



Quelques ordres de grandeur 3/3

▶ Une définition

MapReduce

Bases NoSQL

Dases 1405Q1

Travaux dirigés

Travaux pratiques

⊳ Pétaoctet

- Tout le contenu de toutes les bibliothèques américaines de recherche académique
- 5 ans de données d'observation de la Terre par les satellites de la NASA
- - Tous les mots prononcés par tous les humains depuis toujours
- - Toutes les données stockées sur la planète aujourd'hui
- - 0 ?



Le BigData en volume

▶ Une définition

MapReduce

Bases NoSQL

Travaux dirigés

$$o \ll Ko \ll Mo \ll Go \ll To \ll Po \ll Eo \ll Zo \ll Yo$$
BigData

- ▶ Les SGBD "classiques" peuvent ne pas être adaptés à ces volumétries
- ▷ Ces projets nécessitent :
 - Un système de fichiers distribués
 - Une méthode de traitement de données distribuées



MapReduce

Hadoop

Bases NoSQL

Travaux dirigés

Travaux pratiques

Quelques cas d'usage BigData



- - Classification et Recommandation
- Détection de fraude
- ▷ Écoute téléphonique



MapReduce



▶ MapReduce

Hadoop Bases NoSQL

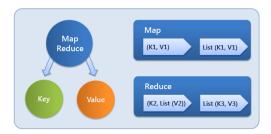
Dases 1403Q

Travaux dirigés

Travaux pratiques

MapReduce

- ▷ Paradigme de programmation adapté au traitement de données distribuées
- Deux fonctions à implémenter
 - Map
 - Reduce
- ▷ N'est PAS temps réel
- ⊳ Clé/valeur





Une définition

▶ MapReduce

Hadoop

Bases NoSQL

Travaux dirigés

Travaux pratiques Phase 0 : Les données sont initialement distribuées



Fichiers en entrée



Phase 1: les Mappers traitent les input splits

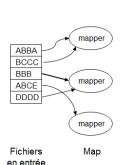
Une définition

► MapReduce

Hadoop

Bases NoSQL

Travaux dirigés





Phase 2 : Les sorties de Mappers sont regroupées et triées

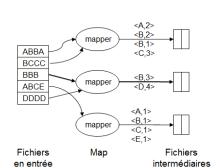
Une définition

► MapReduce

Hadoop

Bases NoSQL

Travaux dirigés





Phase 3: Les Reducers traitent les fichiers intermédiaires

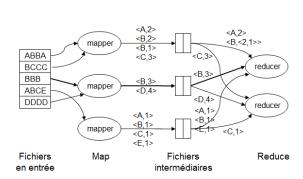
Une définition

► MapReduce

Hadoop

Bases NoSQL

Travaux dirigés





Une définition

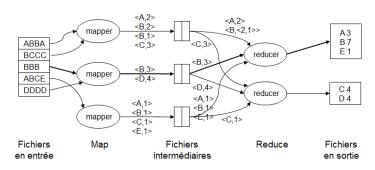
▶ MapReduce

Hadoop

Bases NoSQL

Travaux dirigés
Travaux pratiques

Phase 4 : Le résultat final est enregistré





Hadoop



Hadoop

Une définition

MapReduce

► Hadoop

Bases NoSQL

Travaux dirigés

Travaux pratiques



⊳ Hadoop est

- Un stockage distribué : HDFS
- Un framework de traitement : MapReduce
- ⊳ Existe depuis 2005

- ▷ Inspiré des travaux de Google



MapReduce

► Hadoop

Bases NoSQL

Travaux dirigés

Travaux pratiques

Architecture Hadoop: Le Master



- ▷ 1 Master
- - NameNode : Responsable des données sur HDFS
 - SecondaryNameNode : Backup du NameNode
 - JobTracker : Responsable des Jobs MapReduce



MapReduce

▶ Hadoop

Bases NoSQL

Travaux dirigés

Travaux pratiques

Architecture Hadoop: Les Slaves



- ▶ 1-10000 Slaves
- ▶ Hardware "low cost"
 - DataNode : Stocke les données
 - TaskTracker : Éxecute les tâches



HDFS

Une définition

MapReduce

► Hadoop

Bases NoSQL

Travaux dirigés

Travaux pratiques

- ▷ Système de gros fichiers distribués
- ▷ Scalable horizontalement
- ⊳ Résilient (réplication)
- ▷ Blocs de 64 Mo par défaut

Block Replication

NameNode (Filename, numReplicas, block-ids, ...) /users/sameerp/data/part-0, r:2, {1, 3}, ... /users/sameerp/data/part-1, r:3, {2, 4, 5}, ...

DataNodes





WordCount : TokenizerMapper

Une définition

MapReduce

▶ Hadoop

Bases NoSQL

Travaux dirigés

```
private Text word = new Text();
private final static IntWritable one =
                            new IntWritable(1):
public void map(Object key,
                Text value.
                Context context) {
   StringTokenizer itr =
            new StringTokenizer(value.toString());
   while (itr.hasMoreTokens()) {
        word.set(itr.nextToken()):
        context.write(word, one);
```



WordCount : IntSumReducer

Une définition

MapReduce

▶ Hadoop

Bases NoSQL

Travaux dirigés

```
private IntWritable result = new IntWritable():
public void reduce (Text key,
                    Iterable < IntWritable > values,
                    Context context) {
    int sum = 0:
    for (IntWritable val : values) {
        sum += val.get();
   result.set(sum):
    context.write(key, result);
```





MapReduce

▶ Hadoop

Bases NoSQL

Travaux dirigés

```
public static void main(String[] args) throws Exception {
   Configuration conf = new Configuration();
   Job job = Job.getInstance(conf, "word, count");
   job.setJarByClass(WordCount.class);
   job.setMapperClass(TokenizerMapper.class);
   job.setCombinerClass(IntSumReducer.class);
   job.setReducerClass(IntSumReducer.class);
   job.setOutputKeyClass(Text.class);
   job.setOutputValueClass(IntWritable.class);
   FileInputFormat.addInputPath(job, new Path(args[0]));
   FileOutputFormat.setOutputPath(job, new Path(args[1]));
   System.exit(job.waitForCompletion(true) ? 0 : 1);
```



Bases NoSQL





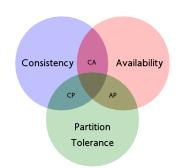
MapReduce

.. .

► Bases NoSQL

Travaux dirigés

Travaux pratiques



Théorème CAP

Tout système distribué ne peut vérifier plus de deux des trois propriétés suivantes :

- Consistency: tous les nœuds du système voient exactement les mêmes données au même moment
- Availability: garantie que toutes les requêtes reçoivent une réponse
- Partition tolerance: en cas de morcellement en sous-réseaux, chacun doit pouvoir fonctionner de manière autonome





MapReduce

Hadoop

▶ Bases NoSQL

Travaux dirigés



- ▷ Base de données orientée colonnes
- ▷ Inspirée de Google Big Table
- De Cohérente et tolérante au partitionnement
- - Facebook
 - Linkedin
 - Netflix



MapReduce

Hadoon

▶ Bases NoSQL

Travaux dirigés

Travaux pratiques

HBase : le modèle de stockage

Table A				
rowkey	Column family	Column qualifier	timestamp	value
ā	cf1	"bar"	"1368394583" "1368394261"	7 "hello"
		"foo"	"1368394583" "1368394925" "1368393847"	22 136 "world"
	cf2	"2011-07-04" "1.0001"	"1368396302" "1368387684"	"fourth of July" "almost the loneliest number"
b	cf2	"thumb"	"1368387684"	"[3.6 kb png data]"

- ▷ Les rowKeys sont triées et shardées automatiquement
- ▶ Les columnFamilies :
 - sont stockées dans des fichiers différents
 - contiennent un nombre quelqconque de paires clé/valeur versionnées



MapReduce

Hadoop

► Bases NoSQL

Travaux dirigés

MongoDB



- ▶ Base de données orientée documents
- > Stocke des Collections de documents BSON

```
"_id": ObjectId("4efa8d2b7d284dad101e4bc7"),
"Nom": "DUMONT".
"Prénom": "Jean",
"Âge": 43
```





MapReduce

Hadoop

▶ Bases NoSQL

Travaux dirigés



- ▷ Base de données orientée graphes
- ⊳ Existe depuis 2000



Travaux dirigés



Architecture hardware BigData

Une définition

MapReduce Hadoop

Bases NoSQL

▶ Travaux

dirigés

Travaux

Une entreprise souhaite analyser les 2 To de logs quotidiens générés par ses serveurs.

Exercice

Proposer une architecture BigData permettant de gérer ce besoin. Vous devrez choisir:

- Le nombre de machines
- Leurs CPUs
- Leur RAM
- Leurs disques durs
- Leur système d'exploitation

Hive



Une définition

MapReduce

Hadoop

Bases NoSQL

▶ Travaux dirigés

Travaux pratiques

Hive est une infrastructure d'entrepôt de données permettant de requêter des données stockées dans Hadoop avec un langage SQL-like.

Exercice

Proposer une implémentation MapReduce des requêtes suivantes :

- SELECT name FROM Employee WHERE depid = 42
- SELECT depid, COUNT(*) FROM Employee GROUP BY depid
- SELECT E.name, D.desc FROM Employee AS E INNER JOIN Department AS D ON (E.depid = D.depid) (cas Department ≪ 1 Go)
- SELECT E.name, D.desc FROM Employee AS E INNER JOIN Department AS D ON (E.depid = D.depid) (cas général)





Stockage de données météo historisées

Une définition

MapReduce Hadoop

Bases NoSQL

Dases NOSQ

► Travaux dirigés

Travaux pratiques

Exercice

On dispose pour chaque ville de France, des relevés des température, de pluviométrie et de pression atmosphérique de chaque seconde depuis 1900.

Quel volume de données (en octets) cela représente-il approximativement ? Comment s'assurer que les relevés sont exhaustifs et corrects ?

Comment stocker efficacement ces données (type de support physique, système de gestion des données, modèle de données, ...) pour répondre le plus efficacement possible aux questions suivantes ?

- Quelle température faisait-il à Champs-sur-Marne, le 26 juin 1942 à 17:31:07 ?
- Dans quelle ville a-t-il le plus plu le 29 juillet 2002 ?
- En quelle année la pression atmosphérique a-t-elle été maximale à Grenoble ?
- Pleut-il vraiment plus en Bretagne ?
- Dans quelle ville et quand, le record de température a-t-il été atteint ?
- Quelles sont les cinq villes ayant eu le plus grand écart de température journalier en 1942 ?

On veut tracer sur une graphe, l'évolution depuis 1900 des températures de Paris, comment procéder ?





Analysons Wikipedia

Une définition

MapReduce

Hadoop

Bases NoSQL

Travaux dirigés

► Travaux pratiques



Wikipedia propose de télécharger un dump de tout son contenu. En date du 13 janvier 2016, en ne sélectionnant que les dernières révisions des articles anglais, sans fichiers ni images, sans discussions, on obtient un XML compressé de 11.7 Go.



Analysons Wikipedia

Une définition

MapReduce

Hadoop

Bases NoSQL

Travaux dirigés

► Travaux pratiques

Énoncé

Expliquer l'intérêt du format BZip2 dans le cadre d'un traitement de données distribuées.

En utilisant le framework Hadoop, répondez aux questions suivantes à propos des articles de Wikipedia :

- Quel est l'article le plus long ?
- Combien d'articles traitent de Hadoop ?
- Qui est le plus gros contributeur ?
- Quels sont les 100 mots les plus fréquents ?
- Quel article est le plus référencé par les autres articles ?
- Quels articles ont le plus de mots distincts en commum ?



